Общее

FMA = 2 Flops

FP32 = 4 bytes на парам

Compute

для свертки с кернелом $K \cdot K$, падингом p, страйдом s выходные высота и ширина

$$H_0 = \left\lfloor \frac{H+2p-k}{s} \right\rfloor + 1$$

$$W_0 = \left\lfloor \frac{W+2p-k}{s} \right\rfloor + 1$$

Каждое выходное значение требует $C_{in} \cdot K^2$ MACs = FMAs

$$\Rightarrow F_{conv} = \underbrace{2B}\,\underbrace{H_0 W_0}\,C_{out} \cdot C_{in}\,k^2$$

Для каждой свертки:

$$F_1 = 2B(S/2)^2 \cdot 32 \cdot 3 \cdot 7^2 = 2352\,BS^2$$

$$F_2 = 2B(S/4)^2 \cdot 64 \cdot 32 \cdot 5^2 = 6400 \cdot BS^2$$

$$F_3 = 2B(S/8)^2 \cdot 128 \cdot 64 \cdot 3^2 = 2304\,BS^2$$

$$F_4 = 2B(S/8)^2 \cdot 256 \cdot 128 = 1024\,BS^2$$

$$F_5 = 2B(S/16)^2 \cdot 256 \cdot 256 \cdot 3^2 = 4608\,BS^2$$

$$F_6 = 2B(S/16)^2 \cdot 512 \cdot 256 = 1024\,BS^2$$

Global AvgPool: HW − 1 adds + 1 division/channel

$$\Rightarrow F = BCHW = B \cdot 512\,(S/16)^2 = 2BS^2$$

Linear: $(m,k)(k,n) \to (m,n)$

$$F = 2mnk$$

$$\Rightarrow F_{fc_1} = 2 \cdot B \cdot 512 \cdot 256 = 262144B$$

$$F_{fc_2} = 2 \cdot B \cdot 256 \cdot 100 = 51200\,B$$

$$B\left[17714S^2 + 313344\right] = FLOPs(S,b)$$

Память

Weights + Activations

$$weights = 3 \cdot 32 \cdot 7^2 + 32 \cdot 64 \cdot 5^2 + 64 \cdot 128 \cdot 3^2 + 128 \cdot 256 + 256^2 \cdot 3^2 + 256 \cdot 512 + 512 \cdot 256 + 256 \cdot 100 = 1039968 \text{ параметров}$$

$$Активации = \underbrace{3BS^2}_{input} + \underbrace{8BS^2}_{conv1\ out} + \underbrace{2BS^2}_{max\ pool\ out} + \underbrace{4BS^2}_{conv2\ out} + \underbrace{2BS^2}_{conv3\ out} + \underbrace{4BS^2}_{conv4\ out} + \underbrace{BS^2}_{conv5\ out} + \underbrace{2BS^2}_{conv6\ out} + \underbrace{512B}_{glob\ avg\ pool\ out} + \underbrace{256B}_{fc_1\ out} + \underbrace{100B}_{fc_2\ out} = 26BS^2 + 868B$$

$$4\left(1039968 + 26BS^2 + 868B\right) \text{ байт} = Memory(S,B)$$

OOM: ≥ 16 GB для T4

* Не учитываю контекст CUDA overhead от torch, etc

Relu inplace ⇒ 0

* в ТГ канале был вопрос про активации — я сохраняю все активации в аналитической модели

Bytes moved

* без bias

Пусть свертка, Relu, линейный слой читают веса и активации с прошлого слоя 1 раз и записывают активации 1 раз

$$\Rightarrow \text{трафик для сверток} = \underbrace{4 \text{ байта}}_{1\ парам}\left[\underbrace{\underbrace{BS}_{размер\ батча} \cdot \underbrace{S^2}_{размер\ картинки} \cdot \underbrace{C_{in}}_{кол\text{-}во\ входных\ каналов}}_{чтение\ активаций\ с\ прошлой\ операции} + \underbrace{BS \cdot S_{out}^2 \cdot C_{out}}_{запись\ активаций} + \underbrace{K^2 \cdot C_{in} \cdot C_{out}}_{веса}\right]$$

$$\text{Линейный слой трафик} = 4 \text{ байта}\left[\underbrace{BS \cdot F_{in}}_{чтение\ активаций} + \underbrace{BS \cdot F_{out}}_{запись\ активаций} + \underbrace{F_{in} \cdot F_{out}}_{загрузка\ весов}\right]$$

$$\text{Relu трафик} = 4 \text{ байт}\left[\underbrace{BS \cdot \underbrace{C}_{каналы} \cdot S^2}_{чтение\ акт.} + \underbrace{BS \cdot C \cdot S^2}_{запись\ акт.} + \underbrace{\cancel{0}}_{веса}\right]$$

$$\text{global avg pool трафик} = 4 \text{ байта}\left[\underbrace{BS \cdot C \cdot S^2}_{чтение\ акт.} + \underbrace{BS \cdot C}_{запись\ акт.} + \underbrace{\cancel{0}}_{веса}\right]$$

Операция	Чтение акт.	Чтен весов	Запись акт.
conv 1	$4B \cdot 3 \cdot S^2$	$4 \cdot 7^2 \cdot 3 \cdot 32$	$4B \cdot 32\,(S/2)^2$
Relu 1	$4B \cdot 32 \cdot (S/2)^2$	0	= чтение акт.
Max Pool	$4B \cdot 32 \cdot (S/2)^2$	0	$4B \cdot 32 \cdot (S/4)^2$
Conv2	$4B \cdot 32 \cdot (S/4)^2$	$4 \cdot 5^2 \cdot 32 \cdot 64$	$4B \cdot 64 \cdot (S/4)^2$
Relu 2	$4B \cdot 64 \cdot (S/4)^2$	0	= чтение акт
Conv 3	$4B \cdot 64 \cdot (S/4)^2$	$4 \cdot 3^2 \cdot 64 \cdot 128$	$4B \cdot 128 \cdot (S/8)^2$
Relu 3	$4B \cdot 128 \cdot (S/8)^2$	0	= чтение акт
Conv 4	$4B \cdot 128 \cdot (S/8)^2$	$4 \cdot 1^2 \cdot 128 \cdot 256$	$4B \cdot 256 \cdot (S/8)^2$
Relu 4	$4B \cdot 256 \cdot (S/8)^2$	0	= чтение акт.
Conv5	$4B \cdot 256 \cdot (S/8)^2$	$4 \cdot 3^2 \cdot 256 \cdot 256$	$4B \cdot 256 \cdot (S/16)^2$
Relu 5	$4B \cdot 256 \cdot (S/16)^2$	0	= чтение акт
Conv 6	$4B \cdot 256 \cdot (S/16)^2$	$4 \cdot 1^2 \cdot 256 \cdot 512$	$4B \cdot 512 \cdot (S/16)^2$
Relu 6	$4B \cdot 512 \cdot (S/16)^2$	0	= чтение акт
GAP	$4B \cdot 512 \cdot (S/16)^2$	0	$4B \cdot 512 \cdot 1^2$
Linear 1	$4B \cdot 512$	$4 \cdot 512 \cdot 256$	$4B \cdot 256$
Relu 7	$4B \cdot 256$	0	= чтение актив
Linear 2	$4B \cdot 256$	$4 \cdot 256 \cdot 100$	$4B \cdot 100$

$$Q(S,b) = 364 \cdot BS^2 + 8592B + 4159872 \text{ байт}$$

Latency

$$\underbrace{17_{\text{запусков кернелов}} \cdot \alpha}_{\text{Launch overhead = время запуска кернела}} + \max\left(\frac{\overbrace{Flops}^{Flops(S,B)}}{\underbrace{Flops/s}_{\beta\text{ — скорость вычислений}}}, \frac{\overbrace{bytes\ moved}^{Q(S,b)}}{\underbrace{bytes/s}_{\gamma\text{ — скорость памяти}}}\right) = Latency(S, B, \underbrace{\theta}_{\alpha,\beta,\gamma})$$

* max, т.к. предполагается что вычисления перекрываются с чтением/записью

Energy

$$E = \overbrace{\overset{Дж/с\ \cdot\ с}{\alpha} \cdot Latency(S,B,\theta)}^{Дж} + \overbrace{\beta \cdot FLOPS(S,b)}^{Дж} + \overbrace{\gamma \cdot Q(S,b)}^{Дж}$$

- $\alpha \cdot Latency$: кол-во энергии от того что GPU просто запущена
- $\beta \cdot FLOPS$: кол-во энергии на все FLOPs
- $\gamma \cdot Q$: кол-во энергии от операций с памятью

Дж

Modes

Launch bound: $17\alpha > \frac{Flops(S,B)}{flops/s} \wedge 17\alpha > \frac{Q(S,b)}{bytes/s}$

Memory bound: $\frac{Q(S,B)}{bytes/s} > 17\alpha \wedge \frac{Q(S,B)}{bytes/s} > \frac{Flops(S,B)}{flops/s}$

Compute bound: $\frac{Flops(S,B)}{flops/s} > 17\alpha \wedge \frac{Flops(S,B)}{flops/s} > \frac{Q(S,B)}{bytes/s}$

(* кеш не учитывается